

PONTIFICIA UNIVERSIDAD JAVERIANA

Facultad de Ingeniería
Introducción a la Inteligencia Artificial

TALLER EDA – FASE 1

Análisis Exploratorio de Datos y Preprocesamiento
Dataset: Adult (Census Income) – UCI Repository

Presentado por:

Nicolás Torres Roa
Nicolás Castañeda Vargas
Juan David Rincón Muñoz
Juan Daniel Ortiz Quecán

Presentado a:

Ing. Julio Omar Palacio Niño, M.Sc.

Bogotá D.C., 2026

TABLA DE CONTENIDO

1. INTRODUCCIÓN.....	3
2. DESCRIPCIÓN DEL DATASET.....	4
2.1 Variables del Dataset.....	4
2.2 Variable Objetivo.....	4
3. ANÁLISIS EXPLORATORIO DE DATOS (EDA).....	6
3.1 Estadísticas Descriptivas.....	6
3.2 Análisis Gráfico.....	6
3.3 Matriz de Correlación.....	8
4. PREPROCESAMIENTO DE LA INFORMACIÓN.....	9
4.1 Tratamiento de Valores Nulos.....	9
4.2 Identificación y Manejo de Valores Atípicos.....	9
4.3 Dummificación de Variables Categóricas.....	10
4.4 Normalización.....	10
5. CONSTRUCCIÓN DEL DATASET DE TRABAJO.....	11
5.1 Particionamiento Entrenamiento / Prueba.....	11
5.2 Justificación de la Proporción 80/20.....	11
5.3 Análisis del Impacto de Variar las Proporciones.....	11
6. CONCLUSIONES.....	12
7. REFERENCIAS.....	13

1. INTRODUCCIÓN

El presente informe corresponde al desarrollo del Taller EDA – Fase 1 del proyecto final de Machine Learning en la asignatura Introducción a la Inteligencia Artificial de la Pontificia Universidad Javeriana. El objetivo principal es aplicar técnicas de análisis exploratorio de datos (EDA) y preprocesamiento sobre el dataset "Adult (Census Income)" del repositorio UCI, con el propósito de garantizar la calidad y pertinencia de la información antes de construir los modelos de clasificación de las fases posteriores.

El dataset Adult recopila información del Censo de los Estados Unidos de 1994 y permite predecir si el ingreso anual de una persona supera los US\$50,000 a partir de variables sociodemográficas y laborales. Este tipo de problema de clasificación binaria es de amplio interés en el campo del machine learning y la ciencia de datos.

2. DESCRIPCIÓN DEL DATASET

El dataset Adult (Census Income) está disponible en el repositorio UCI Machine Learning Repository y se distribuye en dos archivos: adult.data (32.561 registros de entrenamiento) y adult.test (16.281 registros de prueba). Para este análisis ambos archivos se consolidaron en un único conjunto de 48.842 registros, lo que aumenta la base estadística del análisis exploratorio y del posterior particionamiento.

2.1 Variables del Dataset

El dataset contiene 14 variables de entrada y 1 variable objetivo. A continuación se describe cada una.

Tabla 1. Diccionario de variables del dataset Adult.

Variable	Tipo	Descripción
age	N Numérica	Edad del individuo (17–90 años)
workclass	C Categórica	Tipo de empleador (Private, Self-emp, Gov, etc.)
fnlwgt	N Numérica	Peso censal asignado por la CPS
education	C Categórica	Nivel educativo alcanzado
education_num	N Numérica	Representación numérica del nivel educativo (1–16)
marital_status	C Categórica	Estado civil del individuo
occupation	C Categórica	Tipo de ocupación laboral
relationship	C Categórica	Relación familiar del individuo
race	C Categórica	Origen racial del individuo
sex	C Categórica	Género del individuo (Male / Female)
capital_gain	N Numérica	Ganancias de capital reportadas
capital_loss	N Numérica	Pérdidas de capital reportadas
hours_per_week	N Numérica	Horas trabajadas por semana
native_country	C Categórica	País de origen del individuo
income	O Objetivo	Ingreso anual: <=50K o >50K

2.2 Variable Objetivo

La variable objetivo es income, que indica si el ingreso anual supera los US\$50,000. Toma dos valores: "<=50K" (clase negativa) y ">50K" (clase positiva). El conteo real sobre los 48.842 registros muestra 37.155 casos de la clase <=50K (76,07%) y 11.687 de la clase >50K (23,93%). Existe por tanto un desbalance de clases cercano a 76/24 que deberá considerarse en la construcción y evaluación de los modelos de las fases siguientes.




Figura 1. Distribución de la variable objetivo income.

3. ANÁLISIS EXPLORATORIO DE DATOS (EDA)

3.1 Estadísticas Descriptivas

Se realizó un análisis estadístico descriptivo sobre las seis variables numéricas del dataset. La edad promedio es de 38,64 años (mínimo 17, máximo 90). La variable `hours_per_week` presenta una media de 40,42 horas, coherente con la jornada laboral estándar. Las variables `capital_gain` y `capital_loss` presentan distribuciones altamente asimétricas, con mediana cero, lo que indica que la mayoría de personas no reporta ganancias ni pérdidas de capital.

Tabla 2. Estadísticas descriptivas de las variables numéricas.

Variable	Media	Desv. Est.	Mínimo	Mediana	Máximo
age	38,64	13,71	17	37	90
fnlwtgt	189.664	105.604	12.285	178.145	1.490.400
education_num	10,08	2,57	1	10	16
capital_gain	1.079,07	7.452,02	0	0	99.999
capital_loss	87,50	403,00	0	0	4.356
hours_per_week	40,42	12,39	1	40	99

3.2 Análisis Gráfico

Se generaron histogramas, boxplots y gráficos de barras para las variables numéricas y categóricas. Los histogramas confirman la fuerte asimetría de `capital_gain` y `capital_loss` y la concentración de `hours_per_week` alrededor de las 40 horas.




Figura 2. Distribución de las variables numéricas.

Los boxplots segmentados por la variable objetivo permiten observar diferencias en la distribución de age, education_num y hours_per_week entre personas con ingresos superiores e inferiores a US\$50,000: las personas con ingresos >50K tienden a ser mayores, con mayor nivel educativo y más horas de trabajo semanal.




Figura 3. Variables numéricas segmentadas por clase de ingreso.

En cuanto a las variables categóricas, ciertos niveles de occupation (Exec-managerial, Prof-specialty) y de education (Bachelors, Masters, Doctorate) concentran una mayor proporción de personas con ingresos superiores a US\$50,000.




Figura 4. Distribución de occupation por clase de ingreso.




Figura 5. Distribución de education por clase de ingreso.

3.3 Matriz de Correlación

La matriz de correlación entre las variables numéricas revela que education_num es la que presenta mayor correlación positiva con la variable objetivo (0,333), seguida de hours_per_week (0,228), age (0,230) y capital_gain (0,223). Las correlaciones entre las propias variables numéricas son bajas (por ejemplo, age-education_num = 0,031), lo que indica baja multicolinealidad entre ellas. No obstante, la variable categórica education y su versión ordinal education_num son conceptualmente redundantes (education_num es la codificación numérica de education), por lo que se recomienda conservar únicamente education_num en el modelado.




Figura 6. Matriz de correlación de las variables numéricas.

4. PREPROCESAMIENTO DE LA INFORMACIÓN

4.1 Tratamiento de Valores Nulos

Los valores faltantes (representados con "?" en los archivos originales) se concentran en tres columnas del conjunto consolidado: workclass (2.799 nulos, 5,73%), occupation (2.809 nulos, 5,75%) y native_country (857 nulos, 1,75%). Dado que el porcentaje de faltantes es bajo (inferior al 6%), se optó por la imputación con la moda de cada variable. Esta estrategia preserva la distribución original de los datos y evita la pérdida de información que implicaría eliminar los registros incompletos.




Figura 7. Porcentaje de valores nulos por columna.

4.2 Identificación y Manejo de Valores Atípicos

Se aplicó el método del Rango Intercuartílico (IQR) para identificar outliers en las variables numéricas. Las variables con mayor proporción de valores atípicos fueron hours_per_week (27,63%, asociada a jornadas muy cortas o muy largas) y capital_gain (8,26%). Para capital_gain y capital_loss, cuyas distribuciones son extremadamente asimétricas, se aplicó winsorización al percentil 99 (15.024 y 2.001 respectivamente), reemplazando los valores superiores por dicho límite. Esta técnica conserva todos los registros mientras mitiga el efecto distorsionador de los valores extremos.

Tabla 3. Valores atípicos detectados por el método IQR.

Variable	Outliers (n)	Porcentaje
age	216	0,44%
fnlwgt	1.453	2,97%
education_num	1.794	3,67%
capital_gain	4.035	8,26%
capital_loss	2.282	4,67%
hours_per_week	13.496	27,63%

4.3 Dummificación de Variables Categóricas

Las variables categóricas (workclass, education, marital_status, occupation, relationship, race, sex y native_country) se transformaron mediante codificación one-hot (pd.get_dummies). Se aplicó el parámetro drop_first=True para eliminar una categoría por variable y evitar el problema de multicolinealidad conocido como "trampa de la variable ficticia". Dado que native_country posee 41 categorías y education 16, el número de columnas pasó de 15 (14 variables + objetivo) a 98, es decir, 97 variables de entrada (features) más la variable objetivo.

4.4 Normalización

Las variables numéricas continuas (age, fnlwgt, education_num, capital_gain, capital_loss y hours_per_week) se normalizaron con MinMaxScaler, llevando todos los valores al rango [0, 1]. Este ajuste de escala es fundamental para algoritmos sensibles a la magnitud de las variables, como las redes neuronales (Fase 2) y los clasificadores probabilísticos que asumen distribuciones acotadas (Fase 3).

5. CONSTRUCCIÓN DEL DATASET DE TRABAJO

5.1 Particionamiento Entrenamiento / Prueba

El dataset procesado se dividió con `train_test_split` de `sklearn` en una proporción de 80% para entrenamiento y 20% para prueba. Con 48.842 registros, esto resulta en 39.073 registros de entrenamiento y 9.769 de prueba. Se fijó `random_state=42` para garantizar la reproducibilidad y se empleó `stratify=y`, lo que asegura que la distribución de clases (76/24) se mantenga proporcional en ambos subconjuntos (muestreo estratificado), aspecto particularmente importante dado el desbalance presente.




Figura 8. Impacto del porcentaje de partición sobre el tamaño de los subconjuntos.

5.2 Justificación de la Proporción 80/20

La proporción 80/20 es un estándar ampliamente adoptado en la literatura por tres razones: (1) con más de 48.000 registros, el 20% destina cerca de 9.700 muestras a prueba, número suficiente para estimar el error de generalización con confianza; (2) el 80% de datos de entrenamiento permite que el modelo aprenda patrones complejos sin incurrir en sobreajuste por falta de datos; (3) la relación costo-beneficio es óptima, pues aumentar el conjunto de prueba más allá del 20% reduciría el rendimiento sin ganar precisión evaluativa sustancial.

5.3 Análisis del Impacto de Variar las Proporciones

Una proporción de prueba menor al 15% puede generar estimaciones de rendimiento poco confiables por el reducido tamaño muestral. Una proporción mayor al 30% sacrifica datos de entrenamiento y puede deteriorar la capacidad predictiva. En datasets con desbalance, variar las proporciones sin estratificación puede alterar significativamente la distribución de clases en los subconjuntos, introduciendo sesgo en la evaluación; de ahí la importancia de mantener `stratify=y` en todos los escenarios.

6. CONCLUSIONES

El análisis exploratorio del dataset Adult permitió identificar un desbalance de clases real de 76/24 en la variable income, que deberá considerarse en el modelado y la evaluación. Las variables más discriminantes son education_num, age, hours_per_week y capital_gain, que muestran diferencias apreciables entre las dos clases de ingreso.

El preprocesamiento aplicado garantiza la calidad del dataset: se imputaron los valores nulos con la moda, se controlaron los outliers de capital_gain y capital_loss mediante winsorización al percentil 99, se transformaron las variables categóricas con one-hot encoding (obteniendo 97 features) y se normalizaron las numéricas con MinMaxScaler. El particionamiento estratificado 80/20 produce conjuntos de entrenamiento (39.073) y prueba (9.769) representativos y reproducibles.

Este trabajo sienta las bases para la Fase 2 del proyecto, en la que se construirán y evaluarán tres arquitecturas de redes neuronales feed-forward (Perceptrón, red con una capa oculta y red con dos capas ocultas) sobre el dataset ya procesado y particionado.

7. REFERENCIAS

Becker, B. & Kohavi, R. (1996). Adult [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5XW20>

McKinney, W. (2010). Data Structures for Statistical Computing in Python. Proceedings of the 9th Python in Science Conference, 56-61.

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.

ICONTEC. (2008). Norma Técnica Colombiana NTC 1486: Documentación, presentación de tesis, trabajos de grado y otros trabajos de investigación. Instituto Colombiano de Normas Técnicas y Certificación.