

PONTIFICIA UNIVERSIDAD JAVERIANA

Facultad de Ingeniería
Introducción a la Inteligencia Artificial

PROYECTO – FASE 2

Redes Neuronales Feed-Forward para Clasificación de Ingresos
Dataset: Adult (Census Income) – UCI Repository

Presentado por:

Nicolás Torres Roa
Nicolás Castañeda Vargas
Juan David Rincón Muñoz
Juan Daniel Ortiz Quecán

Presentado a:

Ing. Julio Omar Palacio Niño, M.Sc.

Bogotá D.C., 2026

TABLA DE CONTENIDO

1. INTRODUCCIÓN.....	3
2. DATASET Y PARTICIONAMIENTO (FASE 1).....	4
3. FUNDAMENTOS TEÓRICOS DE LAS ARQUITECTURAS.....	5
3.1 Modelo A: Perceptrón.....	5
3.2 Modelo B: Red Neuronal con una Capa Oculta.....	5
3.3 Modelo C: Red Neuronal con dos Capas Ocultas.....	5
4. IMPLEMENTACIÓN TÉCNICA.....	6
4.1 Resumen de Arquitecturas.....	6
4.2 Detalles de Entrenamiento.....	6
4.3 Manejo del Desbalance de Clases.....	6
5. RESULTADOS Y ANÁLISIS COMPARATIVO.....	7
5.1 Métricas de Desempeño.....	7
5.2 Análisis de las Matrices de Confusión.....	7
5.3 Discusión Comparativa.....	9
6. CONCLUSIONES.....	10
7. REFERENCIAS.....	11

1. INTRODUCCIÓN

El presente informe corresponde a la Fase 2 del proyecto final de Machine Learning de la asignatura Introducción a la Inteligencia Artificial de la Pontificia Universidad Javeriana. El objetivo es diseñar, implementar y evaluar tres arquitecturas de redes neuronales feed-forward para resolver el problema de clasificación binaria sobre el dataset Adult (Census Income), determinando cuál arquitectura presenta el mejor desempeño.

Las tres arquitecturas implementadas son: (A) un Perceptrón clásico como clasificador lineal de referencia; (B) una red neuronal con una capa oculta de 97 neuronas (igual al número de variables de entrada); y (C) una red neuronal con dos capas ocultas de exactamente dos neuronas cada una. Todos los modelos incluyen el término de sesgo (bias) en cada neurona, y los modelos B y C utilizan la función sigmoide como función de activación tanto en las capas ocultas como en la de salida.

2. DATASET Y PARTICIONAMIENTO (FASE 1)

Se utilizó el dataset procesado y particionado en la Fase 1. El conjunto Adult consolidado contiene 48.842 registros con 14 variables de entrada que, tras el one-hot encoding con `drop_first=True`, resultan en 97 variables de entrada (features). La variable objetivo `income` es binaria: $\leq 50K$ (clase 0) y $> 50K$ (clase 1). El particionamiento estratificado 80/20 produce 39.073 registros de entrenamiento y 9.769 de prueba.

El dataset presenta un desbalance de clases real de 76/24 (76,07% $\leq 50K$, 23,93% $> 50K$). Este desbalance es una consideración crítica al interpretar las métricas: un clasificador trivial que siempre prediga la clase mayoritaria alcanzaría cerca del 76% de accuracy sin poder predictivo real. Por esta razón, el F1-score de la clase positiva ($> 50K$) es la métrica más relevante para comparar los modelos.

3. FUNDAMENTOS TEÓRICOS DE LAS ARQUITECTURAS

3.1 Modelo A: Perceptrón

El Perceptrón, propuesto por Frank Rosenblatt en 1958, es el modelo más elemental de clasificación lineal. Dado un vector de entradas x , calcula una combinación lineal ponderada más un sesgo b y aplica una función de activación escalón (step) para producir la predicción: $\hat{y} = f(w^T \cdot x + b)$, donde $f(z) = 1$ si $z \geq 0$, y 0 en caso contrario.

El aprendizaje se realiza mediante la regla del Perceptrón: los pesos se actualizan únicamente cuando el modelo comete un error de clasificación. El teorema de convergencia garantiza que el algoritmo converge si los datos son linealmente separables. Su principal limitación es que solo puede aprender fronteras de decisión lineales; problemas no linealmente separables (como XOR) no pueden ser resueltos por esta arquitectura.

3.2 Modelo B: Red Neuronal con una Capa Oculta

La incorporación de una capa oculta con función de activación no lineal (sigmoide) permite al modelo aprender representaciones intermedias y aproximar fronteras de decisión no lineales. La función sigmoide se define como $\sigma(z) = 1 / (1 + e^{(-z)})$, con salida en el rango (0, 1).

El teorema universal de aproximación establece que una red con una sola capa oculta y suficientes neuronas puede aproximar cualquier función continua con precisión arbitraria. Con 97 neuronas en la capa oculta (igual al número de variables de entrada), el Modelo B dispone de capacidad representacional suficiente para capturar las relaciones no lineales del dataset Adult. El entrenamiento se realiza mediante retropropagación (backpropagation) con el optimizador Adam y función de pérdida de entropía cruzada binaria.

3.3 Modelo C: Red Neuronal con dos Capas Ocultas

El Modelo C introduce dos capas de transformación no lineal. En principio, las redes profundas pueden aprender jerarquías de características de forma más eficiente; sin embargo, la restricción de exactamente 2 neuronas por capa oculta crea un cuello de botella extremo: las 97 variables de entrada deben comprimirse a solo 2 representaciones intermedias. Esta limitación de capacidad hace que el modelo sea incapaz de capturar la complejidad del problema.

Este contraste arquitectónico es instructivo: la profundidad de una red no garantiza un mejor rendimiento si la capacidad de cada capa es insuficiente. El número de neuronas por capa es tan crítico como el número de capas.

4. IMPLEMENTACIÓN TÉCNICA

4.1 Resumen de Arquitecturas

Tabla 1. Comparación de las tres arquitecturas implementadas.

Característica	Modelo A	Modelo B	Modelo C
Capas ocultas	0	1	2
Neuronas por capa	N/A	97	2 + 2
Activación oculta	Escalón	Sigmoide	Sigmoide
Activación salida	Escalón	Sigmoide	Sigmoide
Bias incluido	Sí	Sí	Sí
Parámetros (aprox.)	98	9.604	219
Librería	scikit-learn	Keras/TF	Keras/TF
Capacidad	Lineal	Alta	Muy baja

4.2 Detalles de Entrenamiento

Para los modelos B y C se empleó una red feed-forward entrenada con el optimizador Adam (tasa de aprendizaje 0,001) y función de pérdida de entropía cruzada binaria, estándar para clasificación binaria. Se utilizó parada temprana (EarlyStopping) con paciencia de 10 épocas sobre la pérdida de validación para evitar el sobreajuste, restaurando los mejores pesos observados. El tamaño de lote (batch) fue de 256 registros y se reservó un 15% del conjunto de entrenamiento como validación interna para monitorear las curvas de aprendizaje.

4.3 Manejo del Desbalance de Clases

El desbalance 76/24 puede inducir sesgo hacia la clase mayoritaria. Se monitoreó el F1-score de la clase positiva (>50K) como métrica principal. En los casos donde el desbalance afecta significativamente el recall, estrategias como `class_weight="balanced"` o técnicas de remuestreo (SMOTE) podrían aplicarse en iteraciones futuras.

5. RESULTADOS Y ANÁLISIS COMPARATIVO

5.1 Métricas de Desempeño

La Tabla 2 consolida las métricas de evaluación de los tres modelos sobre el conjunto de prueba (9.769 registros).

Tabla 2. Métricas de desempeño sobre el conjunto de prueba.

Modelo	Accuracy	Precision	Recall	F1-score
Modelo A: Perceptrón	0,8181	0,6085	0,6728	0,6390
Modelo B: 1 capa oculta (97n)	0,8498	0,7392	0,5757	0,6473
Modelo C: 2 capas (2+2n)	0,7607	0,0000	0,0000	0,0000




Figura 1. Comparación de métricas de los modelos A, B y C.

5.2 Análisis de las Matrices de Confusión

Las matrices de confusión permiten analizar los tipos de error de cada modelo. El Modelo B obtiene el mayor número de Verdaderos Positivos con alta precisión (1.346 aciertos de la clase >50K y solo 475 falsos positivos), aunque deja escapar parte de la clase positiva (992 falsos negativos), lo que explica su recall moderado. El Modelo A (Perceptrón) reparte mejor entre precisión y recall (1.573 verdaderos positivos). El Modelo C colapsa por completo hacia la clase mayoritaria: predice $\leq 50K$ para todos los registros (0 verdaderos positivos), confirmando el efecto del cuello de botella de 2 neuronas y arrojando precisión, recall y F1 iguales a cero.




Figura 2. Matriz de confusión – Modelo A (Perceptrón).




Figura 3. Matriz de confusión – Modelo B (1 capa oculta).




Figura 4. Matriz de confusión – Modelo C (2 capas, cuello de botella).




Figura 5. Curvas de pérdida durante el entrenamiento de los modelos B y C.

5.3 Discusión Comparativa

El Modelo B es la mejor arquitectura para este problema, con el mayor F1-score (0,6473) y el mayor accuracy (84,98%). Su capa oculta de 97 neuronas con activación sigmoide le permite aprender fronteras de decisión no lineales y privilegia la precisión sobre el recall, comportándose de forma conservadora al declarar la clase positiva.

El Modelo A (Perceptrón) constituye una línea base sólida: con un F1-score de 0,6390 queda muy cerca del Modelo B, lo que indica que buena parte del problema es separable de forma aproximadamente lineal en el espacio de 97 dimensiones generado por el one-hot encoding. Sin embargo, su menor precisión (0,6085) evidencia las limitaciones del modelo lineal.

El Modelo C ilustra que la profundidad sin capacidad es contraproducente: la compresión $97 \rightarrow 2 \rightarrow 2 \rightarrow 1$ elimina la información discriminativa en la primera capa y conduce al colapso hacia la clase mayoritaria (accuracy 0,7607, exactamente la proporción de la clase negativa, con $F1 = 0$). Este resultado demuestra empíricamente que el número de neuronas por capa es tan determinante como el número de capas.

6. CONCLUSIONES

La Fase 2 demostró que la arquitectura óptima para clasificar el dataset Adult entre los tres modelos evaluados es el Modelo B (red con una capa oculta de 97 neuronas), con F1-score de 0,6473 y accuracy de 84,98%. Este resultado confirma en la práctica el teorema universal de aproximación: una red con suficiente capacidad en su capa oculta puede modelar relaciones no lineales complejas.

El Modelo C evidencia que la profundidad sin capacidad es contraproducente: la restricción de 2 neuronas por capa crea un cuello de botella que impide el aprendizaje y produce el colapso del clasificador hacia la clase mayoritaria. El Perceptrón, pese a su simplicidad, resulta sorprendentemente competitivo (F1 = 0,6390), apenas por debajo del Modelo B.

El desbalance de clases (76/24) exige interpretar el accuracy con cautela; el F1-score de la clase positiva es el indicador más informativo. El mejor modelo de esta fase (Modelo B) servirá como referencia para el análisis comparativo de la Fase 3 frente a un algoritmo clásico de Machine Learning.

7. REFERENCIAS

- Goodfellow, I., Bengio, Y. & Courville, A. (2016). Deep Learning. MIT Press.
- Chollet, F. (2021). Deep Learning with Python (2nd ed.). Manning Publications.
- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.
- Becker, B. & Kohavi, R. (1996). Adult [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5XW20>
- ICONTEC. (2008). Norma Técnica Colombiana NTC 1486: Documentación, presentación de tesis, trabajos de grado y otros trabajos de investigación.