

PONTIFICIA UNIVERSIDAD JAVERIANA

Facultad de Ingeniería
Introducción a la Inteligencia Artificial

INVESTIGACIÓN – FASE 3

Naive Bayes: Implementación, Evaluación y Contraste con Redes Neuronales
Dataset: Adult (Census Income) – UCI Repository

Presentado por:

Nicolás Torres Roa
Nicolás Castañeda Vargas
Juan David Rincón Muñoz
Juan Daniel Ortiz Quecán

Presentado a:

Ing. Julio Omar Palacio Niño, M.Sc.

Bogotá D.C., 2026

TABLA DE CONTENIDO

1. INTRODUCCIÓN.....	3
2. FUNDAMENTACIÓN TEÓRICA DEL ALGORITMO NAIVE BAYES.....	4
2.1 El Teorema de Bayes.....	4
2.2 El Supuesto de Independencia Condicional (Naive).....	4
2.3 Variantes según la Distribución de las Características.....	4
2.4 Manejo del Desbalance de Clases.....	4
2.5 Ventajas y Limitaciones.....	5
3. HIPERPARÁMETROS DEL MODELO.....	6
4. IMPLEMENTACIÓN PRÁCTICA.....	7
4.1 Dataset y Particionamiento.....	7
4.2 Selección de Variante y Ajuste.....	7
5. RESULTADOS Y ANÁLISIS COMPARATIVO.....	8
5.1 Métricas: Naive Bayes vs Redes Neuronales.....	8
5.2 Análisis de las Curvas ROC.....	10
5.3 Discusión: Naive Bayes vs Redes Neuronales.....	10
6. CONCLUSIONES.....	12
7. REFERENCIAS.....	13

1. INTRODUCCIÓN

El presente documento corresponde a la Fase 3 del proyecto final de Machine Learning de la asignatura Introducción a la Inteligencia Artificial de la Pontificia Universidad Javeriana. El propósito es el estudio, implementación y evaluación del algoritmo Naive Bayes como técnica clásica de clasificación, contrastando su rendimiento frente a las tres arquitecturas de redes neuronales desarrolladas en la Fase 2 sobre el dataset Adult (Census Income).

Naive Bayes fue seleccionado por sus fundamentos matemáticos sólidos basados en el Teorema de Bayes, su eficiencia computacional y su comportamiento particular ante el desbalance de clases del dataset Adult (76% $\leq 50K$, 24% $> 50K$).

2. FUNDAMENTACIÓN TEÓRICA DEL ALGORITMO NAIVE BAYES

2.1 El Teorema de Bayes

El fundamento matemático de Naive Bayes es el Teorema de Bayes, que describe la probabilidad posterior de una clase C_k dado un vector de observaciones $x = (x_1, x_2, \dots, x_n)$: $P(C_k | x) = P(x | C_k) \cdot P(C_k) / P(x)$.

Donde $P(C_k | x)$ es la probabilidad posterior de la clase k ; $P(x | C_k)$ es la verosimilitud del vector de características; $P(C_k)$ es la probabilidad a priori de la clase, estimada de la frecuencia relativa en los datos de entrenamiento; y $P(x)$ es la evidencia, constante para todas las clases y que puede ignorarse al comparar.

2.2 El Supuesto de Independencia Condicional (Naive)

El calificativo "ingenuo" (naive) proviene del supuesto simplificador de que todas las características son condicionalmente independientes dada la clase: $P(x | C_k) = \prod_i P(x_i | C_k)$. Este supuesto raramente se cumple en datos reales; sin embargo, la investigación empírica ha demostrado que Naive Bayes mantiene un rendimiento competitivo incluso cuando las características están correladas, gracias a que el criterio de decisión (argmax de la probabilidad posterior) es robusto a violaciones moderadas del supuesto.

La regla de clasificación final es $\hat{y} = \operatorname{argmax}_k P(C_k) \cdot \prod_i P(x_i | C_k)$. En la práctica, para evitar el underflow numérico de productos de muchas probabilidades pequeñas, se trabaja con log-probabilidades: $\log P(C_k | x) \propto \log P(C_k) + \sum_i \log P(x_i | C_k)$.

2.3 Variantes según la Distribución de las Características

Para el dataset Adult procesado con one-hot encoding, las variables son mayoritariamente binarias (resultado del dummificado) con algunas continuas normalizadas. Por tanto, BernoulliNB y ComplementNB están naturalmente alineadas con el tipo de datos; GaussianNB también se evalúa dado que todas las features quedaron en el rango [0,1].

Tabla 1. Variantes de Naive Bayes evaluadas.

Variante	Distribución $P(x_i C_k)$	Caso de uso óptimo	Hiperparámetro
GaussianNB	Normal $N(\mu, \sigma^2)$	Features continuas normalizadas	var_smoothing
BernoulliNB	Bernoulli	Features binarias (one-hot)	alpha (Laplace)
ComplementNB	Complemento	Datasets desbalanceados	alpha (Laplace)

2.4 Manejo del Desbalance de Clases

Naive Bayes incorpora el prior $P(C_k)$ de forma explícita. Con `fit_prior=True` (por defecto), el modelo estima $P(\leq 50K) \approx 0,76$ y $P(>50K) \approx 0,24$ directamente de los datos de entrenamiento, lo que le da una inclinación natural hacia la clase

mayoritaria proporcional al desbalance. ComplementNB mitiga este problema al modelar el complemento de cada clase, asignando mayor penalización a los errores en la clase minoritaria.

2.5 Ventajas y Limitaciones

Entre las ventajas de Naive Bayes destacan: (1) eficiencia computacional extrema, con entrenamiento $O(n \cdot d)$ sin iteraciones de optimización; (2) buen desempeño con pocos datos y manejo transparente del desbalance; (3) escaso ajuste de hiperparámetros; y (4) probabilidades directamente utilizables para rankear predicciones.

Sus limitaciones principales son: (1) el supuesto de independencia condicional se viola en el dataset Adult, donde variables como education y education_num están correladas; (2) para features continuas, el supuesto gaussiano puede no ajustarse a variables muy asimétricas como capital_gain; y (3) las probabilidades estimadas tienden a la sobreconfianza cuando hay atributos redundantes.

3. HIPERPARÁMETROS DEL MODELO

El ajuste de hiperparámetros se realizó mediante validación cruzada estratificada de 5-fold sobre el conjunto de entrenamiento, optimizando el F1-score de la clase positiva (>50K). Se exploró `var_smoothing` en el rango $[1e-12, 1]$ (30 valores logarítmicos) y `alpha` en $[0,001, 100]$ (30 valores logarítmicos).

Tabla 2. Hiperparámetros principales de Naive Bayes y su efecto.

Hiperparámetro	Variante	Efecto sobre el modelo	Rango
<code>var_smoothing</code>	GaussianNB	Fracción de varianza máxima sumada a σ^2 . Evita varianzas cero y mejora la estabilidad numérica.	1e-12 a 1
<code>alpha</code>	BernoulliNB	Suavizado de Laplace: añade <code>alpha</code> a los conteos. <code>alpha=1</code> es el suavizado estándar.	0,001 a 100
<code>alpha</code>	ComplementNB	Igual concepto; al modelar el complemento, controla la penalización sobre la clase mayoritaria.	0,001 a 100
<code>fit_prior</code>	Todas	Si True, estima $P(C_k)$ de los datos (absorbe el desbalance); si False, usa prior uniforme.	True / False

Los valores óptimos hallados por validación cruzada fueron `var_smoothing` $\approx 0,149$ para GaussianNB y `alpha` $\approx 6,21$ para BernoulliNB.

4. IMPLEMENTACIÓN PRÁCTICA

4.1 Dataset y Particionamiento

Se utilizó el mismo pipeline de la Fase 1: consolidación de adult.data y adult.test (48.842 registros), imputación de nulos con la moda en workclass, occupation y native_country, winsorización al percentil 99 de capital_gain y capital_loss, one-hot encoding con drop_first=True (97 features), normalización MinMaxScaler de las variables numéricas y particionamiento estratificado 80/20 (39.073 entrenamiento / 9.769 prueba, random_state=42).

4.2 Selección de Variante y Ajuste

Se compararon las tres variantes mediante validación cruzada estratificada de 5-fold. En esta comparación inicial, ComplementNB (F1 = 0,641) y BernoulliNB (F1 = 0,638) superaron claramente a GaussianNB (F1 = 0,496), confirmando que las features binarias del one-hot favorecen los modelos de tipo Bernoulli. Posteriormente se realizó la búsqueda en grilla logarítmica del hiperparámetro de cada variante, graficando la curva de F1-score para identificar el valor óptimo.




Figura 1. Ajuste del hiperparámetro var_smoothing (GaussianNB).




Figura 2. Ajuste del hiperparámetro alpha (BernoulliNB).

5. RESULTADOS Y ANÁLISIS COMPARATIVO

5.1 Métricas: Naive Bayes vs Redes Neuronales

La Tabla 3 consolida las métricas de las tres variantes de Naive Bayes (optimizadas) junto con los resultados de las redes neuronales de la Fase 2, evaluadas todas sobre el mismo conjunto de prueba de 9.769 registros.

Tabla 3. Comparativo global: Naive Bayes vs Redes Neuronales (Fase 2).

Modelo	Accuracy	Precision	Recall	F1-score
GaussianNB (opt.)	0,7725	0,5151	0,8452	0,6401
BernoulliNB (opt.)	0,8042	0,5695	0,7447	0,6454
ComplementNB	0,7710	0,5130	0,8499	0,6398
Fase 2 – Perceptrón	0,8181	0,6085	0,6728	0,6390
Fase 2 – Red B (97n)	0,8498	0,7392	0,5757	0,6473
Fase 2 – Red C (2+2n)	0,7607	0,0000	0,0000	0,0000




Figura 3. Comparación de métricas de las variantes de Naive Bayes.

De las variantes de Naive Bayes, BernoulliNB obtuvo el mejor F1-score sobre el conjunto de prueba (0,6454), seguida muy de cerca por GaussianNB (0,6401) y ComplementNB (0,6398). Es destacable que las variantes gaussiana y complemento alcanzan un recall muy alto (0,845 y 0,850), es decir, identifican la mayoría de las personas con ingresos >50K, a costa de una menor precisión.




Figura 4. Matriz de confusión – BernoulliNB (mejor variante).




Figura 5. Matriz de confusión – GaussianNB.




Figura 6. Matriz de confusión – ComplementNB.

5.2 Análisis de las Curvas ROC

La curva ROC grafica la Tasa de Verdaderos Positivos (recall) frente a la Tasa de Falsos Positivos para distintos umbrales. El área bajo la curva (AUC) resume la capacidad discriminante del modelo: AUC = 1 indica clasificación perfecta y AUC = 0,5 equivale a un clasificador aleatorio. Las tres variantes obtuvieron un AUC alto y similar: GaussianNB 0,885, ComplementNB 0,885 y BernoulliNB 0,876, lo que confirma que, en términos de capacidad de discriminación global, Naive Bayes es muy competitivo.




Figura 7. Curvas ROC de las variantes de Naive Bayes.

5.3 Discusión: Naive Bayes vs Redes Neuronales

El hallazgo central del análisis comparativo es que el mejor modelo global sigue siendo la red neuronal de la Fase 2 (Modelo B, $F1 = 0,6473$), pero la diferencia frente al mejor Naive Bayes (BernoulliNB, $F1 = 0,6454$) es mínima: apenas 0,0019 puntos de F1. En otras palabras, un clasificador probabilístico que se entrena en una fracción del tiempo y sin retropropagación iguala prácticamente el desempeño de la red neuronal.

La diferencia de paradigma se refleja en el perfil de errores. La red neuronal B privilegia la precisión (0,739) y es conservadora al declarar la clase positiva, mientras que las variantes gaussiana y complemento de Naive Bayes privilegian el recall ($\approx 0,85$), recuperando muchas más personas de altos ingresos a costa de más falsos positivos. La elección entre uno u otro depende del costo relativo de los falsos negativos frente a los falsos positivos en la aplicación.

Para el dataset Adult, la violación del supuesto de independencia (variables como education y education_num, u occupation y workclass, están correladas) afecta la calibración de las probabilidades de Naive Bayes, pero no su decisión de clasificación, lo que explica su buen desempeño. El Modelo C de la Fase 2 ($F1 = 0$) queda muy por debajo de cualquier variante de Naive Bayes, confirmando que la arquitectura de la red importa más que la mera presencia de capas ocultas.

6. CONCLUSIONES

El análisis de Naive Bayes sobre el dataset Adult demuestra que los algoritmos probabilísticos clásicos mantienen plena relevancia en problemas de clasificación tabular: la mejor variante (BernoulliNB, $F1 = 0,6454$) quedó a menos de 0,002 puntos del mejor modelo de red neuronal ($F1 = 0,6473$), con un costo computacional órdenes de magnitud menor. La selección de la variante adecuada según el tipo de datos resultó tan importante como el ajuste de hiperparámetros: las variantes Bernoulli y Complemento superaron ampliamente a la Gaussiana en validación cruzada.

La comparación con la Fase 2 evidencia el trade-off fundamental del Machine Learning: mayor capacidad del modelo implica mayor potencial de rendimiento, pero también mayor costo computacional, más datos para evitar el sobreajuste y menor interpretabilidad. Naive Bayes ofrece entrenamiento casi instantáneo, probabilidades interpretables y robustez ante el desbalance, igualando en la práctica el desempeño predictivo de la red neuronal.

Este contraste no determina un "mejor" algoritmo en términos absolutos, sino que ilustra la importancia de seleccionar la técnica según los requerimientos del problema: si el tiempo de entrenamiento, la interpretabilidad o la actualización incremental son prioritarios, Naive Bayes es una opción altamente competitiva frente a las redes neuronales.

7. REFERENCIAS

Mitchell, T. M. (1997). Machine Learning. McGraw-Hill. Capítulo 6: Bayesian Learning.

Murphy, K. P. (2012). Machine Learning: A Probabilistic Perspective. MIT Press.

Rish, I. (2001). An empirical study of the naive Bayes classifier. IJCAI Workshop on Empirical Methods in AI.

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.

Becker, B. & Kohavi, R. (1996). Adult [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5XW20>

ICONTEC. (2008). Norma Técnica Colombiana NTC 1486: Documentación, presentación de tesis, trabajos de grado y otros trabajos de investigación.